



Centro Integrado de Inteligência Artificial

NIAEdu

Sistema de Detecção de Anomalias no Cartão PDAF

Uma análise sobre as atividades gerais desenvolvidas

Autores:

Danilo Naves do Nascimento

Lurian Correia Lima

Mariana Monteiro Bispo

Carolina Fernandes de Campos

Milena Beatriz Aires de Santana Dias

Supervisão Acadêmica:

Prof. Dr. Victor Rafael R. Celestino

Brasília, DF

28 de novembro de 2025

Resumo

Este relatório apresenta os resultados da pesquisa desenvolvida, no ano de 2025, em uma das frentes de estudo do Núcleo de Educação NIAEdu: Inteligência Artificial na Predição de Detecção de Anomalias no Programa de Descentralização Administrativa e Financeira (PDAF) do Governo do Distrito Federal (GDF). O PDAF é uma iniciativa da Secretaria de Educação do Distrito Federal que visa descentralizar e otimizar a gestão administrativa e financeira das escolas públicas do DF. O problema central abordado foi a necessidade de aprimorar os mecanismos de auditoria e controle na gestão dos recursos do Cartão PDAF. O objetivo geral foi o desenvolvimento de uma prova de conceito (PoC) de um sistema de IA para identificar anomalias e fraudes na gestão do Cartão PDAF. A Metodologia empregada foi a pesquisa exploratória. A partir de dados secundários públicos, referentes ao PDAF ou de *datasets* sobre detecção de anomalias, diversos tipos de aprendizado de máquina e modelos preditivos foram testados. Uma análise comparativa do desempenho foi realizada para propor alternativas para a continuidade da pesquisa. Os objetivos foram alcançados, com a identificação de limitações e a proposição de oportunidades de trabalhos futuros.

Palavras-chave: PDAF, GDF, Inteligência Artificial, Detecção de Anomalias.

Conteúdo

Resumo	1
1 Introdução	4
2 Fundamentação Teórica	5
2.1 Objeto de Estudo	5
2.1.1 Natureza e objetivos	5
2.1.2 Evolução normativa	5
2.1.3 Gestão operacional dos recursos	5
2.1.4 Cartão PDAF	6
2.2 Detecção de Anomalias e Irregularidades por Inteligência Artificial	6
3 Metodologia	6
3.1 População e Amostra	7
3.2 Coleta de Dados	7
3.2.1 Dados públicos	7
3.2.2 Dados de referência	7
3.3 Análise de Dados	8
3.4 Tipos de aprendizado de máquina	8
3.4.1 Aprendizado supervisionado	8
3.4.2 Aprendizado não supervisionado	8
3.5 Estudo dos modelos preditivos	9
3.5.1 Random Forest	9
3.5.2 Isolation Forest	10
3.5.3 XGBoost (Extreme Gradient Boosting)	10
3.5.4 CatBoost	11
3.5.5 LASSO Regression	11
3.5.6 Transformers para Dados Tabulares	12
3.6 Técnicas de Balanceamento de Classes	15
3.6.1 Oversampling	15
3.6.2 Undersampling	15
3.6.3 Dataset real	16
4 Resultados e Discussão	17
4.1 Análise de Dados Públicos	17
4.1.1 Análise do consumo de 2024	17
4.1.2 Análise do consumo de 2025	22
4.2 Estudo sobre Dataset Semelhante	26

4.2.1	Análise Comparativa entre os Algoritmos	27
4.2.2	Discussão dos Resultados	30
4.2.3	Estudo de Modelo Híbrido	31
4.2.4	Resultados do Modelo Híbrido	32
4.2.5	Repositórios e Códigos Fonte	33
4.3	Análise Comparativa da Qualidade dos Resultados Obtidos	34
5	Conclusão	34
5.1	Objetivos	35
5.2	Limitações	35
5.3	Oportunidades de Trabalhos Futuros	36

1 Introdução

O Programa de Descentralização Administrativa e Financeira (PDAF) é uma iniciativa da Secretaria de Educação do Distrito Federal que visa descentralizar e otimizar a gestão administrativa e financeira das escolas públicas do DF. O programa concede recursos financeiros complementares e suplementares diretamente às unidades escolares e coordenações regionais de ensino, promovendo maior autonomia na utilização dos recursos e na tomada de decisões, conforme suas necessidades específicas.

Neste contexto, o Cartão PDAF é um instrumento financeiro criado e regulamentado pelo Decreto nº 42.403, de 18 de agosto de 2021, com o objetivo de agilizar e simplificar a gestão de recursos nas escolas públicas e nas Coordenações Regionais de Ensino (CREs) da rede pública do Distrito Federal. Desse modo, o PDAF foi concebido para garantir a eficiência, transparência e celeridade na prestação de contas dos recursos públicos descentralizados.

No entanto, o Tribunal de Contas do Distrito Federal (TCDF) e outras instituições de controle, como o Ministério Público de Contas do DF, têm monitorado a aplicação dos recursos do PDAF para assegurar a sua correta aplicação. Nos últimos anos, esses órgãos têm acatado representações e denúncias relacionadas ao repasse de recursos para o cartão PDAF e a indícios de falhas na execução de seus recursos.

O problema central a ser abordado nesta pesquisa é a necessidade de aprimorar os mecanismos de auditoria e controle na gestão dos recursos do Cartão PDAF. Neste sentido, formula-se a seguinte questão de pesquisa: "Como utilizar a inteligência artificial (IA) para identificar e prevenir anomalias e fraudes que comprometem a eficiência e a transparência na aplicação desses recursos?"

Com base nisso, este projeto de pesquisa tem como objetivo geral o desenvolvimento de uma prova de conceito (PoC) de um sistema de IA para identificar anomalias e fraudes na gestão do Cartão PDAF. Esta pesquisa pretende abordar os seguintes objetivos específicos:

1. Levantar bibliografia relacionada ao PDAF e à detecção de anomalias com inteligência artificial (IA);
2. Coletar dados secundários do PDAF e de bases públicas disponíveis relacionadas;
3. Identificar modelos de IA aplicáveis e testar em bases de dados disponíveis;
4. Avaliar o desempenho comparativo dos modelos e propor alternativas para o futuro desenvolvimento de um produto mínimo viável (MVP) de um sistema para identificar anomalias e fraudes na gestão do cartão PDAF.

2 Fundamentação Teórica

2.1 Objeto de Estudo

2.1.1 Natureza e objetivos

O PDAF é instituído pela Lei Distrital nº 6.023/2017, que tem por finalidade “constituir-se como um mecanismo de descentralização financeira, de caráter complementar e suplementar”, destinado a prover recursos a escolas e coordenações regionais de ensino para que desenvolvam iniciativas de melhoria do ensino [DODF nº 241, seção 1, 2 e 3 de 19/12/2017]. Ao descentralizar a gestão desses bens, a lei busca dar às unidades escolares autonomia para atender despesas de menor porte sem a demora dos procedimentos licitatórios.

2.1.2 Evolução normativa

O PDAF originou-se de um processo iniciado ainda na década de 1990. A Lei Distrital nº 250/1992 autorizou a direção das escolas a administrar verbas dentro do limite de dispensa de licitação [DODF nº 70, seção 1, 2 e 3 de 06/04/1992]; o Decreto nº 20.306/1999 regulamentou esses repasses; em 2007 o Decreto nº 28.513 revogou normas anteriores e substituiu o Programa de Descentralização de Recursos Financeiros (PDRF) pelo atual PDAF; e em 2012 o Decreto nº 33.867 regulamentou o PDAF até a aprovação da Lei 6.023/2017.

2.1.3 Gestão operacional dos recursos

A operacionalização se divide em duas grandes etapas: a transferência dos recursos e sua posterior execução. A transferência ocorre anualmente, por meio de duas parcelas semestrais, cujos valores são definidos pela Secretaria de Educação. O principal critério para o cálculo da distribuição é o número de estudantes matriculados em cada escola no ano anterior, o que possibilita uma alocação proporcional. Além disso, o sistema prevê repasses adicionais para unidades com demandas específicas.

Uma vez que os recursos são transferidos, tem-se a fase de execução, que é a gestão e utilização do dinheiro para concretizar os objetivos pedagógicos e administrativos da instituição. Contudo, o uso desses fundos não é vago. Antes de qualquer despesa, a gestão da escola, junto com a unidade executora (UEX), deve elaborar um Plano de Aplicação Anual, detalhando os gastos para o ano.

Uma condição fundamental para que uma escola receba os recursos é a adimplência, ou seja, ela precisa estar com a prestação de contas dos anos anteriores em dia.

2.1.4 Cartão PDAF

Por meio do Decreto nº 42.403/2021, o Cartão PDAF foi regulamentado como a ferramenta exclusiva de manejo dos recursos distribuídos às escolas contempladas, conferindo maior transparência e eficiência na prestação de contas. A proposta é se utilizar de um sistema informatizado para facilitar os trâmites de pequenas reformas e arrefecer a burocracia.

Ressalta-se que é proibido usar o cartão PDAF para pagar salários, multas ou juros, realizar despesas com publicidade que promova pessoas nem adquirir bens e serviços já fornecidos pela Secretaria de Educação. Também não é permitido pagar por despesas realizadas antes do recebimento do crédito. Qualquer situação excepcional ou caso omissor exige uma deliberação prévia da SEEDF. O objetivo é direcionar a aplicação correta e responsável dos fundos.

2.2 Detecção de Anomalias e Irregularidades por Inteligência Artificial

Os recentes avanços no aprendizado de máquina (ML) têm sido fundamentais na detecção de anomalias e irregularidades nos processos de compras públicas, utilizando diversos conjuntos de dados e metodologias em vários contextos. Estudos recentes [1, 4, 13, 19, 22] ilustram o potencial significativo que técnicas de ML/IA têm assumido na previsão de irregularidades em licitações públicas, ressaltando o impacto das novas tecnologias no aprimoramento das auditorias financeiras em um ambiente de big data, para identificar transações irregulares aproveitando características específicas dos contratos e indicadores quantitativos[3, 17].

Desse modo, algoritmos de detecção de anomalias, como árvores de decisão (DT), *Random Forest* (RF), *Isolation Forest* (IF), *Gradient Boosted Decision Trees* (GBDTs), e redes neurais baseadas na arquitetura de Transformers tabulares, têm se mostrado eficazes na identificação de eventos considerados fora do padrão esperado em diversos domínios, incluindo física, tráfego, e segurança cibernética. A aplicação combinada com métodos de balanceamento de dados aumenta significativamente a eficácia na detecção de anomalias, pois melhora o equilíbrio entre classes, reduzindo falsos positivos e aumentando o recall das detecções. Essa integração é especialmente relevante em cenários onde as anomalias representam uma minoria no conjunto de dados, demandando técnicas avançadas para superar o viés de classe maioria e melhorar a sensibilidade do sistema de detecção. Os tipos de aprendizado de máquina e os modelos aplicados estão detalhados na seção 3.

3 Metodologia

Neste projeto, foi adotada a metodologia de pesquisa exploratória, a fim de compreender melhor o problema, o contexto dos dados e as possíveis relações entre variáveis antes

da modelagem. Desse modo, a metodologia deste trabalho inicia com a coleta de dados públicos e o estudo de datasets relacionados ao tema, a fim de identificar padrões, *outliers* e correlações por meio de análises estatísticas e visualizações. A partir das amostras coletadas, propõe-se um *pipeline* de dados a fim de rotular os dados obtidos e prepará-los para o treinamento dos modelos. Essa abordagem permite formular perguntas mais precisas, definir objetivos realistas e escolher algoritmos adequados, servindo como base para o desenvolvimento de modelos mais robustos e alinhados ao domínio do problema.

3.1 População e Amostra

A população desta pesquisa inclui o universo das escolas públicas que recebem repasse de recursos descentralizados, por mecanismos semelhantes ao PDAF. A amostra que será utilizada para o desenvolvimento da solução é formada pelas escolas públicas do DF. Mais especificamente, serão analisados dados de transações realizadas via PDAF por cada Unidade Executora (UEX), como, por exemplo, o valor de cada transação, sua situação, a data da solicitação e o nome dos fornecedores.

3.2 Coleta de Dados

No âmbito de manipulação dos dados referentes ao PDAF, duas abordagens de coletas diferentes foram adotadas.

3.2.1 Dados públicos

Devido ao teor sensível dos dados a serem estudados, não foi possível receber autorização e acesso aos microdados do dataset real durante este primeiro período de atividades do NIAEdu. A partir disso, dados abertamente divulgados foram obtidos diretamente no portal EducaDF¹, os quais auxiliaram na análise e entendimento inicial da problemática.

3.2.2 Dados de referência

Com base na análise sobre os dados públicos, foi possível direcionar a pesquisa a datasets que tenham características e comportamentos semelhantes aos apresentados publicamente. Os datasets selecionados foram encontrados na plataforma Kaggle².

¹<https://educadf.se.df.gov.br/>

²<https://www.kaggle.com/datasets/kartik2112/fraud-detection/data>

3.3 Análise de Dados

Diversos tipos de aprendizado de máquina e modelos preditivos foram aplicados à análise de dados. O detalhamento da análise de dados encontra-se organizado no GitHub ³.

3.4 Tipos de aprendizado de máquina

Fundamentalmente, o aprendizado de máquina ramifica-se em três paradigmas principais, diferenciados pela natureza do sinal de aprendizado ou informação disponível para o sistema: aprendizado supervisionado, aprendizado não supervisionado e aprendizado por reforço [5, 18]. Enquanto cada uma dessas abordagens possui aplicabilidade distinta, dependendo profundamente da estrutura dos dados e da definição do problema [9], este trabalho delimita seu escopo à exploração e aplicação dos métodos supervisionados e não supervisionados.

3.4.1 Aprendizado supervisionado

No aprendizado supervisionado, o modelo é treinado com um conjunto de dados rotulado, ou seja, cada exemplo de entrada está associado a uma saída ou categoria esperada. O objetivo é aprender uma função que relacione as variáveis de entrada (*features*) às saídas (*labels*), permitindo realizar previsões sobre novos dados. Algoritmos como *Random Forest* ⁴, *Gradient Boosted Decision Trees (GBDT)* ⁵ e *Regressão logística* ⁶ são exemplos típicos dessa abordagem. Esse tipo de aprendizado é amplamente utilizado em tarefas de classificação e regressão, nas quais existe conhecimento prévio sobre o resultado esperado.

3.4.2 Aprendizado não supervisionado

Diferentemente do aprendizado supervisionado, no aprendizado não supervisionado o modelo não recebe rótulos durante o treinamento. O objetivo é identificar estruturas ocultas ou padrões intrínsecos nos dados, agrupando instâncias semelhantes ou detectando comportamentos atípicos. Métodos como *k-Means* ⁷, *Local Outlier Factor (LOF)* ⁸ e *Isolation Forest* ⁹ são exemplos dessa categoria. Essa abordagem é particularmente útil em cenários

³<https://github.com/ciia-educacao>

⁴<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>

⁵<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.GradientBoostingRegressor.html>

⁶https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

⁷<https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>

⁸<https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.LocalOutlierFactor.html>

⁹<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html>

de exploração de dados e detecção de anomalias, nos quais o conjunto de classes não é previamente conhecido.

3.5 Estudo dos modelos preditivos

Durante o desenvolvimento da pesquisa, diferentes algoritmos de aprendizado de máquina foram analisados quanto à sua aplicabilidade na detecção de anomalias, levando em conta aspectos como robustez a ruídos, interpretabilidade e desempenho em cenários desbalanceados. Entre os modelos estudados, destacam-se o *Random Forest*, *Isolation Forest*, *GBDT* e a variante *CatBoost*, e redes neurais com arquitetura baseada em *Transformers tabulares* ¹⁰ e Regressão *Least Absolute Shrinkage and Selection Operator (LASSO)* ¹¹. Cada um desses modelos apresenta características particulares que os tornam mais ou menos adequados a determinadas condições de dados.

3.5.1 Random Forest

O *Random Forest* é um método de aprendizado supervisionado baseado em um conjunto de árvores de decisão[15]. Cada árvore é construída a partir de uma amostra aleatória dos dados, e a cada divisão apenas um subconjunto de variáveis é considerado. Essa aleatoriedade reduz o sobreajuste (*overfitting*) e melhora a capacidade de generalização. Na detecção de anomalias, o *Random Forest* pode ser aplicado por meio de classificadores binários (normal/anômalo) quando há rótulos disponíveis. Seu ponto forte é a robustez frente a ruído e a capacidade de lidar com dados heterogêneos (numéricos e categóricos). Entretanto, sua limitação principal está na dependência de dados rotulados e na dificuldade em capturar anomalias raras se estas forem sub-representadas no treinamento.

Pontos fortes:

- Resistente a sobreajuste e ruídos.
- Suporta variáveis numéricas e categóricas simultaneamente.
- Fornece medidas de importância das variáveis e probabilidades associadas às previsões.

Limitações:

- Necessita de dados rotulados para classificação.
- Menor sensibilidade a anomalias muito raras.
- Pode demandar muitos recursos computacionais com grandes volumes de dados.

¹⁰<https://github.com/yandex-research/rtdl>

¹¹https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Lasso.html

3.5.2 Isolation Forest

O *Isolation Forest* é um algoritmo não supervisionado voltado especificamente à detecção de anomalias[21]. Sua principal premissa é que instâncias anômalas são mais facilmente isoladas do que as instâncias normais, pois apresentam valores distantes ou pouco frequentes nas distribuições das variáveis. O método constrói múltiplas árvores binárias aleatórias e mede o número médio de divisões necessárias para isolar uma amostra. Pontos isolados em poucas divisões são classificados como anomalias.

Pontos fortes:

- Não requer dados rotulados.
- Escalável e eficiente para grandes conjuntos de dados.
- Alta capacidade de identificar anomalias pontuais e locais.

Limitações:

- Pode apresentar desempenho inferior em dados com estruturas complexas ou dependências não lineares.
- Menor interpretabilidade em comparação a modelos supervisionados.
- Sensível à escolha dos hiperparâmetros (número de árvores e profundidade).

3.5.3 XGBoost (Extreme Gradient Boosting)

O *XGBoost* é uma implementação otimizada da técnica de *Gradient Boosting*, projetada para alto desempenho e eficiência computacional. Ele constrói um conjunto sequencial de árvores de decisão, em que cada nova árvore é treinada para corrigir os erros das anteriores, minimizando uma função de perda diferenciável de forma iterativa.

Na detecção de anomalias, o *XGBoost* é particularmente eficaz em contextos supervisionados, nos quais há rótulos disponíveis para indicar comportamentos normais e anômalos. O modelo permite ajustar pesos de classe, tornando-se uma escolha robusta para cenários de desbalanceamento extremo como transações financeiras[11].

Pontos fortes:

- Excelente desempenho em tarefas supervisionadas com forte desbalanceamento entre classes.
- Capacidade de modelar relações complexas e não lineares entre variáveis.
- Oferece interpretabilidade por meio de métricas de importância de atributos e explicações locais.

- Otimizado para velocidade e uso eficiente de memória, com suporte a paralelização.

Limitações:

- Requer dados rotulados, o que restringe sua aplicação em cenários puramente não supervisionados.
- Pode sofrer com *overfitting* em conjuntos de dados pequenos ou altamente ruidosos.
- Exige ajuste cuidadoso de hiperparâmetros para alcançar o melhor desempenho.

3.5.4 CatBoost

O *CatBoost* é uma variação moderna dos métodos de *boosting* baseada em árvores de decisão e otimizada para lidar nativamente com variáveis categóricas e evitar o sobreajuste [16]. Para detecção de anomalias supervisionada, o CatBoost é capaz de lidar com dados heterogêneos e desbalanceados, oferecendo resultados estáveis mesmo com volumes moderados de amostras. Sua codificação ordenada das variáveis categóricas reduz o vazamento de informações, melhorando a generalização.

Pontos fortes:

- Suporte nativo a variáveis categóricas.
- Alta estabilidade e generalização, mesmo com poucos dados.
- Menor necessidade de pré-processamento.

Limitações:

- Exige rótulos para treinamento.
- Pode apresentar desempenho inferior em dados com extrema esparsidade.
- Treinamento mais lento em comparação a modelos mais simples, como o *Isolation Forest*.

3.5.5 LASSO Regression

A regressão *LASSO* (*Least Absolute Shrinkage and Selection Operator*) é um método linear supervisionado que utiliza regularização L1 para reduzir a magnitude dos coeficientes de regressão. Essa penalização força alguns coeficientes a zero, realizando simultaneamente seleção de variáveis e ajuste do modelo. No contexto de detecção de anomalias, o LASSO é útil para identificar atributos que exercem influência desproporcional sobre a variável alvo, sendo particularmente vantajoso em cenários com alta dimensionalidade.

Pontos fortes:

- Promove seleção automática de variáveis relevantes.
- Interpretação direta dos coeficientes do modelo.
- Boa performance com dados lineares e de alta dimensionalidade.

Limitações:

- Requer dados rotulados.
- Desempenho limitado em relações não lineares.
- Sensível à escala das variáveis e à presença de multicolinearidade.

3.5.6 Transformers para Dados Tabulares

Os *Transformers* são modelos originalmente desenvolvidos para tarefas de processamento de linguagem natural, baseados em mecanismos de *self-attention*, que permitem ao modelo capturar dependências entre diferentes partes de uma sequência de entrada de maneira paralela e eficiente. Recentemente[7], variações desses modelos, como o *TabTransformer*[10] e o *FT-Transformer*[14], têm sido aplicadas com sucesso ao domínio de dados tabulares, oferecendo uma alternativa poderosa aos modelos clássicos como árvores de decisão e redes neurais tradicionais.

Esses modelos tratam cada coluna (ou atributo) como um *token*, aplicando camadas de atenção para aprender relações complexas entre as variáveis, independentemente de sua natureza (numérica ou categórica). Essa abordagem permite que o modelo capture interações não lineares e dependências sutis entre atributos, algo que modelos baseados em regras ou árvores podem deixar de explorar completamente.

Pontos Positivos

- Capturam relações complexas entre variáveis, incluindo dependências não lineares e interações de alta ordem;
- Lidam de forma eficiente com variáveis categóricas, especialmente quando codificadas por embeddings;
- Podem generalizar melhor em cenários com grande quantidade de dados e alta dimensionalidade;
- Beneficiam-se de técnicas avançadas de regularização e pré-treinamento, como o *masking* e o *transfer learning*.

Limitações

- Demandam alto custo computacional e maior tempo de treinamento, especialmente para grandes conjuntos de dados;

- São sensíveis à escolha de hiperparâmetros e à qualidade da normalização dos dados;
- Requerem maior quantidade de dados para evitar sobreajuste em comparação a modelos baseados em árvores, como o *XGBoost* ou *CatBoost*;
- Apresentam menor interpretabilidade, o que dificulta sua aplicação em contextos que exigem explicabilidade dos resultados.

Em suma, os *Transformers* tabulares representam uma abordagem promissora para a modelagem de dados estruturados, oferecendo desempenho competitivo em diversos cenários. No entanto, seu uso ainda é mais indicado quando há disponibilidade de dados em grande escala e recursos computacionais adequados.

Modelo	Tipo de aprendizado	Pontos fortes	Limitações
Random Forest	Supervisionado	Robusto a ruídos e desbalanceamento; lida com variáveis mistas; fornece importância das variáveis.	Requer rótulos; sensível a anomalias muito raras; custo computacional elevado.
Isolation Forest	Não supervisionado	Detecta anomalias sem rótulos; escalável; bom para outliers pontuais.	Sensível a parâmetros; menos eficaz em estruturas complexas; baixa interpretabilidade.
XGBoost	Supervisionado	Alta eficiência computacional; regularização embutida reduz <i>overfitting</i> ; excelente desempenho em dados tabulares.	Requer ajuste fino de hiperparâmetros; pode ter tempo de treinamento elevado em grandes volumes de dados; sensível a ruído.
CatBoost	Supervisionado	Suporte nativo a variáveis categóricas; estável; evita vazamento de informação.	Exige rótulos; pode ter desempenho inferior em dados muito esparsos; treinamento mais lento.
LASSO Regression	Supervisionado	Seleção automática de variáveis; interpretável; eficiente em alta dimensionalidade.	Requer rótulos; limitado a relações lineares; sensível à escala das variáveis.
Transformer	Supervisionado	Capturam relações complexas entre variáveis, incluindo dependências não lineares e interações de alta ordem	Custo computacional elevado para o treinamento

Tabela 1: Comparativo entre os modelos de aprendizado aplicados à detecção de anomalias

De modo geral, a combinação de modelos supervisionados (como *Random Forest*, *XGBoost*, *CatBoost* e *LASSO*) e não supervisionados (como o *Isolation Forest*) permite uma

análise mais abrangente do comportamento dos dados, equilibrando precisão e capacidade de detecção de anomalias não previamente conhecidas.

3.6 Técnicas de Balanceamento de Classes

O desbalanceamento de classes é um dos principais desafios em problemas de detecção de anomalias[8], especialmente em contextos financeiros, onde as transações legítimas superam em larga escala as fraudulentas. Esse fenômeno prejudica o desempenho de algoritmos de aprendizado de máquina, pois a maioria tende a favorecer a classe majoritária, reduzindo a sensibilidade à classe minoritária, justamente onde se encontram as anomalias de interesse.

Existem duas abordagens principais para lidar com esse problema: **oversampling** e **undersampling**. Ambas têm o objetivo de ajustar a distribuição das classes, de modo a reduzir o viés do modelo e melhorar sua capacidade de generalização.

3.6.1 Oversampling

O *oversampling* consiste em aumentar o número de instâncias da classe minoritária, criando novas amostras ou replicando as existentes. Essa técnica busca equilibrar o conjunto de dados sem descartar informações da classe majoritária. As principais técnicas incluem:

- **Random Oversampling:** replica aleatoriamente exemplos da classe minoritária até atingir um equilíbrio.
- **SMOTE (Synthetic Minority Over-sampling Technique):** gera novas instâncias sintéticas ao interpolar amostras reais da classe minoritária com seus vizinhos mais próximos.
- **ADASYN (Adaptive Synthetic Sampling):** semelhante ao SMOTE, mas foca a geração de amostras sintéticas nas regiões onde a classe minoritária é mais difícil de aprender.

Embora o *oversampling* preserve toda a informação da classe majoritária, ele pode aumentar o risco de *overfitting*, especialmente quando a criação de exemplos sintéticos não representa bem a variabilidade real dos dados.

3.6.2 Undersampling

O *undersampling*, por outro lado, reduz o número de instâncias da classe majoritária para tornar as proporções entre as classes mais equilibradas. As principais abordagens incluem:

- **Random Undersampling:** remove aleatoriamente amostras da classe majoritária.

- **Cluster Centroids:** substitui grupos de exemplos majoritários por seus centróides, preservando a representatividade geral da distribuição.
- **NearMiss:** seleciona exemplos da classe majoritária mais próximos das instâncias da classe minoritária, buscando manter os limites de decisão mais bem definidos.

Embora reduza o tempo de treinamento e a dominância da classe majoritária, o *under-sampling* pode levar à perda de informações relevantes, especialmente quando o volume inicial de dados é limitado.

Na prática, é comum empregar uma combinação dessas técnicas ou ainda utilizar abordagens híbridas, como o *SMOTEENN* (combinação de *SMOTE* com limpeza por edição de vizinhos), para alcançar um equilíbrio mais natural entre as classes e melhorar o desempenho do modelo.

3.6.3 Dataset real

Como parte dos dados reais já existentes sobre o manejo de recursos do PDAF, é esperado que o dataset real será obtido com base no paradigma ELT (Extract, Load, Transform), que serão concebidas pela equipe da Diretoria de Informações Educacionais (DINFE) da SEEDF. Desse modo, obtêm-se os dados transformados do banco de dados do PDAF:

Tabela 2: Estrutura da tabela com as principais informações relacionadas ao PDAF

Coluna	Tipo	Descrição
cd_solicitacao	int8	Código da solicitação
unidade_executora	varchar	Unidade executora
ds_tipo_solicitacao	text	Descrição do tipo de solicitação
ds_solicitacao	varchar	Descrição da solicitação
dt_solicitacao	timestamp	Data da solicitação
dt_acao_fornecedor	timestamp	Data da ação do fornecedor
st_acao_fornecedor	text	Status da ação do fornecedor
ds_recusa	varchar	Descrição da recusa
fornecedor	varchar	Fornecedor
dbt_updated_at	timestampz	Data da última transformação

Tabela 3: Estrutura da tabela relativa às Ordens de Serviço(OS)

Coluna	Tipo	Descrição
cd_os	int8	Código da ordem de serviço
cd_solicitacao	int8	Código da solicitação
unidade_executora	varchar	Unidade executora
cd_usuario	varchar	Código do usuário
ds_solicitacao	varchar	Descrição da solicitação
nome_item	varchar	Nome do item
quantidade	numeric(38,9)	Quantidade
preco_unitario	numeric(38,9)	Preço unitário
preco_total	numeric(38,9)	Preço total
ds_processo_sei	varchar	Descrição do processo SEI
data_criacao	timestamp	Data de criação
situacao_os	text	Situação da ordem de serviço
fornecedor	varchar	Fornecedor
vl_total_os	numeric(38,9)	Valor total da OS
vl_subtotal_os	numeric(38,9)	Valor subtotal da OS
justificativa	varchar	Justificativa
dbt_updated_at	timestampz	Data da última transformação

4 Resultados e Discussão

Os resultados são apresentados em conformidade com o cronograma e linha de raciocínios tomados ao longo do projeto.

4.1 Análise de Dados Públicos

Diante do obstáculo do acesso ao dataset real, o estudo dos dados acerca do PDAF foi feito sobre informações disponíveis publicamente na internet.

4.1.1 Análise do consumo de 2024

A tabela a seguir apresenta uma amostra dos dados de consumo do Programa de Descentralização Administrativa e Financeira (PDAF) para o ano de 2024, detalhando os totais e valores de Ordens de Serviço (OS) por Coordenação Regional de Ensino (CRE).

Tabela 4: Amostra do consumo de 2024 do PDAF.

CRE	Período	OS Emitidas	OS Abertas	OS Canceladas	Valor Emitido (R\$)	Valor Aguardando (R\$)	Valor Cancelado (R\$)
CRE - BRAZLÂNDIA	JAN	22	0	0	410877.55	0.0	0.0
CRE - CEILÂNDIA	JAN	16	0	2	349221.50	0.0	12169.0
CRE - GAMA	JAN	8	0	1	352558.19	0.0	0.0
CRE - GUARÁ	JAN	13	0	0	486196.56	0.0	0.0
CRE - NÚCLEO BANDEIRANTE	JAN	9	0	2	119975.21	0.0	22.5

Coordenações Regionais de Ensino (CREs)

Quantas CREs foram contempladas e quais foram? A análise dos dados revelou um total de 15 CREs contempladas. O dataset contém todas as 14 regionais de ensino mais o colégio militar Dom Pedro II. As regionais são:

- BRAZLÂNDIA
- CEILÂNDIA
- GAMA
- GUARÁ
- NÚCLEO BANDEIRANTE
- PARANOÁ
- PLANALTINA
- PLANO PILOTO
- RECANTO DAS EMAS
- SAMAMBAIA
- SANTA MARIA
- SÃO SEBASTIÃO
- SOBRADINHO
- TAGUATINGA
- COLÉGIO MILITAR DOM PEDRO II


Ordens de Serviço (OS)

Segundo o site do governo¹², após a escolha do fornecedor, é gerada uma Ordem de Serviço pelo diretor que fará a inserção de todas as atividades/produtos da contratação. Cada Unidade Executora (UEx) pode e deve formalizar os serviços a serem prestados por meio de Contrato e de acordo com as normas do PDAF.

Quantas Ordens de Serviço foram emitidas por mês? O gráfico de barras abaixo ilustra o total de Ordens de Serviço que foram emitidas mensalmente ao longo de 2024.


¹²Disponível em: gov.br

Figura 1: Total de OS Emitidas por Mês - 2024




Qual a distribuição de OS emitidas por cada CRE? O boxplot a seguir mostra a distribuição da quantidade de OS emitidas para cada uma das CREs, permitindo observar a variabilidade e a mediana de emissões entre as regionais.

Figura 2: Distribuição de OS Emitidas por CRE - 2024




Qual a distribuição de OSs canceladas? Similarmente, o gráfico abaixo apresenta o número de Ordens de Serviço canceladas a cada mês.

Figura 3: Total de OS Canceladas por Mês - 2024



Quantas OS foram abertas por mês? Este gráfico exibe o total de Ordens de Serviço que permaneceram com o status "Abertas" em cada mês de 2024.


Figura 4: Total de OS Abertas por Mês - 2024



Valores


Qual o valor médio por OS emitida? O *heatmap* abaixo detalha o valor médio (em R\$) por Ordem de Serviço emitida, cruzando as informações por CRE e por mês. Células mais escuras indicam um valor médio mais alto.

Figura 5: Valor Médio por OS Emitida - Por CRE e Mês (2024)



O gráfico de barras agrupadas a seguir compara os valores totais emitidos, aguardando pagamento e cancelados para cada CRE. Isso oferece uma visão clara da execução financeira do programa em cada regional.

Figura 6: Valores por CRE - 2024



4.1.2 Análise do consumo de 2025

A tabela a seguir apresenta uma amostra dos dados de consumo do Programa de Descentralização Administrativa e Financeira (PDAF) para o ano de 2025, detalhando os totais e valores de Ordens de Serviço (OS) por Coordenação Regional de Ensino (CRE).

Tabela 5: Amostra do consumo de 2025 do PDAF.

CRE	Período	OS Emitidas	OS Abertas	OS Canceladas	Valor Emitido (R\$)	Valor Aguardando (R\$)	Valor Cancelado (R\$)
CRE - BRAZLÂNDIA	JAN	51	2	3	594009.86	27092.60	18063.27
CRE - CEILÂNDIA	JAN	37	1	0	1084518.37	17769.27	0.00
CRE - GAMA	JAN	12	0	1	394036.42	0.00	202925.11
CRE - GUARÁ	JAN	17	0	0	517131.28	0.00	0.00
CRE - NÚCLEO BANDEIRANTE	JAN	23	1	1	185641.02	6703.50	31897.48

CREs


Quantas CREs foram contempladas e quais foram? A análise dos dados de 2025 revelou um total de 14 CREs contempladas. As regionais são:

- BRAZLÂNDIA
- CEILÂNDIA
- GAMA
- GUARÁ
- NÚCLEO BANDEIRANTE
- PARANOÁ
- PLANALTINA

- PLANO PILOTO
- RECANTO DAS EMAS
- SAMAMBAIA
- SANTA MARIA
- SÃO SEBASTIÃO
- SOBRADINHO
- TAGUATINGA


Ordens de Serviço (OS)

Quantas Ordens de Serviço foram emitidas por mês? O gráfico de barras abaixo ilustra o total de Ordens de Serviço que foram emitidas mensalmente ao longo de 2025.




Qual a distribuição de OS emitidas por cada CRE? O boxplot a seguir mostra a distribuição da quantidade de OS emitidas para cada uma das CREs, permitindo observar a variabilidade e a mediana de emissões entre as regionais em 2025.

Figura 8: Distribuição de OS Emitidas por CRE - 2025




Qual a distribuição de OSs canceladas? Similarmente, o gráfico abaixo apresenta o número de Ordens de Serviço canceladas a cada mês em 2025.

Figura 9: Total de OS Canceladas por Mês - 2025



Quantas OS foram abertas por mês? Este gráfico exibe o total de Ordens de Serviço que permaneceram com o status "Abertas" em cada mês de 2025.


Figura 10: Total de OS Abertas por Mês - 2025
Total de OS Abertas por Mês - 2025



Valores


Qual o valor médio por OS emitida? O *heatmap* abaixo detalha o valor médio (em R\$) por Ordem de Serviço emitida para 2025, cruzando as informações por CRE e por mês. Células mais escuras indicam um valor médio mais alto.

Figura 11: Valor Médio por OS Emitida - Por CRE e Mês (2025)



O gráfico de barras agrupadas a seguir compara os valores totais emitidos, aguardando pagamento e cancelados para cada CRE no ano de 2025.

Figura 12: Valores por CRE - 2025



Repositório no GitHub O repositório central com o código-fonte completo das análises exploratórias de dados pode ser acessado pelo link abaixo:

- **GitHub - EDA PDAF:**

<https://github.com/ciia-educacao/PDAF>

Este repositório contém os dados dos anos de 2023, 2024 e 2025, bem como as Análises exploratórias dos dois últimos anos.

4.2 Estudo sobre Dataset Semelhante

Para fundamentar a análise e validação dos modelos de detecção de anomalias, foi selecionado um conjunto de dados público disponível na plataforma Kaggle, denominado *Fraud Detection Dataset*¹³. Esse dataset contém registros simulados de transações financeiras, rotuladas como legítimas ou fraudulentas, com o objetivo de representar de forma realista o comportamento de sistemas de pagamento no mundo real.

O conjunto de dados é composto por mais de 6 milhões de transações, abrangendo atributos como o valor da transação, tipo de operação (transferência, pagamento, saque etc.), saldo antes e depois da operação, além do identificador das contas envolvidas. A presença

¹³Disponível em: <https://www.kaggle.com/datasets/kartik2112/fraud-detection>

de variáveis numéricas e categóricas torna o conjunto adequado para experimentação com diferentes abordagens de aprendizado supervisionado e não supervisionado.

Um aspecto central desse dataset é o alto desbalanceamento entre as classes: as transações fraudulentas correspondem a uma fração ínfima em comparação às legítimas. Essa característica reflete o cenário real de sistemas financeiros, onde fraudes são eventos raros e esparsos. Esse desbalanceamento impõe desafios significativos na modelagem, pois a maioria dos algoritmos de aprendizado tende a privilegiar a classe majoritária, o que pode resultar em altas taxas de falsos negativos (fraudes não detectadas).

Além do desbalanceamento, outro desafio importante está na rotulagem correta das instâncias. Em aplicações reais, identificar e confirmar uma transação como fraude demanda investigação humana e análise de múltiplas fontes de informação, tornando o processo de rotulagem caro e suscetível a erros. Essa incerteza nos rótulos pode comprometer o treinamento supervisionado e reduzir a generalização do modelo.

Principais desafios observados:

- **Desbalanceamento extremo das classes:** a proporção de transações fraudulentas é muito pequena, exigindo técnicas de reamostragem (como *SMOTE*) ou ajuste de pesos de classe para evitar viés do modelo.
- **Dificuldade de rotulagem:** a obtenção de rótulos precisos de fraude é cara e demorada, podendo introduzir ruído nos dados e impactar a eficácia dos modelos supervisionados.
- **Heterogeneidade dos atributos:** a mistura de variáveis categóricas e numéricas requer pré-processamento cuidadoso para evitar perda de informação.
- **Escalabilidade:** o grande volume de dados pode demandar técnicas de amostragem ou aprendizado incremental para treinamento eficiente.


Em síntese, o *Fraud Detection Dataset* constitui um cenário desafiador e representativo para a validação de algoritmos de detecção de anomalias, permitindo explorar as limitações de modelos tradicionais e a efetividade de abordagens híbridas (supervisionadas e não supervisionadas) diante de contextos reais de fraude financeira.

4.2.1 Análise Comparativa entre os Algoritmos

Para avaliar a eficácia dos algoritmos utilizados na detecção de anomalias, foram analisados os desempenhos do *Random Forest*, *Isolation Forest*, *XGBoost*, *Catboost* e *FT-Transformer* com base nas principais métricas de classificação. Os resultados mostram diferenças significativas em termos de precisão, recall, F1-score.


Random Forest O modelo *Random Forest*, por ser supervisionado, apresentou desempenho muito elevado na classe majoritária (não anomalia), com precisão e recall iguais a 1,00. Para a classe minoritária (anomalia), o modelo utiliza um limiar que prioriza a métrica f1-score, assim sendo, a precisão foi de 90,00% demonstrando uma boa capacidade de identificar corretamente transações fraudulentas. Além disso, o recall para anomalias, foi de 79,00%, indicando que o modelo deixou apenas de identificar apenas 21% das anomalias da base de dados, portanto um resultado interessante para um detector de anomalias em transações.

A figura 13 apresenta a relação entre o limiar de decisão e o F1-score, indicando onde ocorre a harmonia entre ambos.



Na figura 14 por meio do *Permutation Importance* é possível visualizar o valor de importância de cada feature para a decisão final do modelo.


Figura 14: Importâncias de Features - Random Forest



Isolation Forest Por outro lado, o modelo *Isolation Forest*, voltado para detecção de anomalias e aplicado de forma não supervisionada, apresentou um comportamento inverso. O recall da classe de anomalia foi extremamente alto (97,07%), ou seja, quase todas as anomalias foram identificadas. No entanto, o número de falsos positivos foi tão elevado que a acurácia geral caiu para 1,04% e a precisão foi de apenas 0,56%, comprometendo a utilidade prática do modelo quando usado isoladamente.

XGBoost O modelo *XGBoost*, apresentou resultados consistentes na detecção de anomalias. Com o ajuste ideal de limiar, o modelo alcançou uma precisão de 83% e um recall de 80% para a classe de anomalia, resultando em um F1-score de 82%. Esses valores indicam que o modelo conseguiu equilibrar adequadamente a identificação de fraudes (recall) e a minimização de falsos positivos (precisão), apresentando desempenho robusto mesmo em um cenário fortemente desbalanceado. A acurácia global foi de aproximadamente 99,9%, reforçando sua alta capacidade de generalização.

A figura 15 apresenta a correlação entre o limiar de decisão e o F1-score, indicando onde ocorre o equilíbrio entre eles.



Catboost O Catboost apresentou o desempenho de 73,00%, 63,00% e 86,00% nas métricas de F1-score, recall e precisão, respectivamente, para a detecção de casos positivos de anomalias. Além disso, este modelo foi capaz de classificar corretamente todos os casos de não-anomalias. No entanto, vale ressaltar que os valores obtidos se referem ao modelo treinado sem balanceamento de classe.

Transformer Tabular (FT-Transformer) De modo semelhante ao Catboost e ao Random Forest, esse modelo também apresentou um desempenho para a classificação de casos de não-anomalias melhor do que para casos de anomalias. O modelo foi treinado por 60 épocas e atingiu o valor de F1-score de 71,00% para a detecção dos casos de anomalias, próximo ao valor obtido anteriormente pelo Catboost.

4.2.2 Discussão dos Resultados

A Tabela 6 apresenta a comparação das principais métricas de desempenho obtidas pelos modelos testados na detecção de anomalias.

Tabela 6: Comparação das métricas de desempenho entre os modelos analisados (classe de anomalia)

Métrica	Random Forest	Isolation Forest	XGBoost	CatBoost	FT-Transformer
Acurácia	99,83%	1,04%	99,90%	100,00%	98,00%
Precisão	90,00%	0,56%	83,00%	86,00%	79,00%
Recall	79,00%	97,07%	80,00%	63,00%	65,00%
F1-Score	84,00%	1,12%	82,00%	73,00%	71,00%

Os resultados demonstram que os modelos supervisionados, como o *Random Forest*, *CatBoost* e *XGBoost*, apresentaram desempenho mais equilibrado entre as métricas de precisão e *F1-score*, mostrando-se mais confiáveis quando o objetivo é reduzir falsos positivos.

O *Random Forest*, em particular, destacou-se pelo melhor equilíbrio entre **precisão (90%)** e recall (79%), alcançando o maior *F1-score* (84%) entre os modelos supervisionados, o que o torna especialmente adequado para cenários de detecção de fraudes com dados desbalanceados.

Por outro lado, o *Isolation Forest*, sendo um modelo não supervisionado, priorizou a identificação de todas as anomalias (recall de 97,07%), porém com um custo muito elevado em termos de falsos positivos e baixa precisão (0,56%).

O *FT-Transformer* apresentou desempenho intermediário, com um *F1-score* de 71,00%, enquanto o *CatBoost* mostrou-se consistente, atingindo *F1-score* de 73,00% e excelente precisão (86%).

De forma geral, os resultados indicam que modelos supervisionados com regularização adequada e ajustes de limiar tendem a oferecer a melhor relação entre sensibilidade e precisão em tarefas de detecção de anomalias financeiras.

4.2.3 Estudo de Modelo Híbrido

Diante das limitações observadas na aplicação isolada de ambos os algoritmos, propôs-se um modelo híbrido que combina as vantagens do *Isolation Forest* e do *Random Forest*. O objetivo é obter uma maior cobertura de casos de anomalia (alto recall), sem comprometer excessivamente a precisão e a acurácia do sistema.

A ideia central do modelo híbrido consiste em aplicar, inicialmente, o *Isolation Forest* como um filtro de transações. Este algoritmo identifica um subconjunto de transações suspeitas com base em padrões anômalos. Esse subconjunto reduzido é, então, processado por um modelo supervisionado (*Random Forest*), treinado com exemplos rotulados, para realizar a classificação final.

Essa abordagem permite:

- Reduzir significativamente o número de transações que precisam ser avaliadas pelo modelo supervisionado.
- Focar o poder preditivo do *Random Forest* apenas em casos considerados potencialmente suspeitos.
- Aumentar a eficiência computacional e a precisão da detecção de anomalias.

4.2.4 Resultados do Modelo Híbrido

Após aplicar o *Isolation Forest* como filtro inicial, foram selecionadas 12.967 transações suspeitas (aproximadamente 5% da base total). O *Random Forest* foi então utilizado para classificar essas transações.

A Tabela 7 apresenta os resultados obtidos apenas dentro desse subconjunto suspeito:

Tabela 7: Desempenho do Modelo Híbrido (apenas nos casos suspeitos)

Métrica	Valor (Classe anomalia)
Acurácia	0,9937
Precisão	0,8197
Recall	0,8403
F1-Score	0,8299
anomalias Detectadas	238 de 238

Contudo, quando analisamos o desempenho do modelo híbrido em relação à base total (259.335 transações, das quais 1.501 são anomalias), percebemos limitações importantes. A Tabela 8 apresenta os resultados globais:

Tabela 8: Desempenho do Modelo Híbrido (base total)

Métrica	Valor Real (Classe anomalia)
Recall Geral	0,1585
anomalias Detectadas	238 de 1.501
Proporção da Base Avaliada	12.967 de 259.335 (5%)

Apesar do excelente desempenho interno (dentro dos casos suspeitos), o modelo híbrido detectou apenas 15,85% das anomalias reais da base completa. Isso ocorreu porque o *Isolation Forest*, utilizado como filtro, deixou passar a maior parte das anomalias reais (só 238 de 1.501 foram encaminhadas ao *Random Forest*).

Esse resultado evidencia um risco importante: a alta taxa de falsos negativos do filtro de anomalias, o que compromete a eficácia global do sistema. Ainda assim, a etapa de classificação (*Random Forest*) se mostrou eficiente ao processar os casos que lhe foram atribuídos.

4.2.5 Repositórios e Códigos Fonte

Todos os modelos desenvolvidos neste trabalho estão disponíveis para consulta, reprodução e experimentação. Os códigos foram implementados em Python.

Repositório no GitHub O repositório central com o código-fonte completo dos modelos pode ser acessado pelo link abaixo:

- **GitHub - Modelos de Detecção de anomalias:**
https://github.com/ciia-educacao/modelos_pdaf

Este repositório contém os seguintes modelos implementados:

- *Random Forest* supervisionado
- *Isolation Forest* não supervisionado
- Modelo híbrido: *Isolation Forest* + *Random Forest*
- Comparação entre Catboost e FT-Transformer

Notebooks no Kaggle Os notebooks foram publicados no Kaggle com visualização interativa.

- **Modelo Isolation Forest:**
<https://www.kaggle.com/code/danilonaves/detector-de-anomalias-isolation-forest>
- **Modelo Random Forest:**
<https://www.kaggle.com/code/danilonaves/detector-de-anomalias-randomforest>
- **Modelo Híbrido (Isolation + Random Forest):**
<https://www.kaggle.com/code/danilonaves/detector-de-anomalias-randomforest-e-isola>
- **Catboost e FT-Transformer**
<https://www.kaggle.com/code/lurianlima/gbdt-and-ft-transformer>

Todos os notebooks estão devidamente documentados, contendo explicações dos passos e métricas de avaliação.

4.3 Análise Comparativa da Qualidade dos Resultados Obtidos

De acordo com os resultados obtidos, é possível observar que os modelos supervisionados apresentaram desempenho mais estável e equilibrado na detecção de anomalias quando comparados ao modelo não supervisionado *Isolation Forest*. Essa diferença decorre do fato de que os modelos supervisionados, como o *Random Forest*, o *XGBoost* e o *CatBoost*, foram treinados sobre dados rotulados, possibilitando uma melhor distinção entre transações legítimas e fraudulentas.

O *Random Forest* apresentou o melhor equilíbrio entre as métricas, com acurácia de 99,83%, precisão de 90,09%, recall de 79% e F1-score de 84,04% na classe de fraudes. Esses resultados indicam que o modelo consegue identificar corretamente a maior parte das transações fraudulentas, mantendo um número relativamente baixo de falsos positivos.

O *XGBoost* também apresentou desempenho elevado, com precisão de 83%, recall de 80% e F1-score de 82%, e acurácia global de 99,9%.

O *CatBoost* obteve F1-score de 73%, precisão de 86% e recall de 63%, destacando-se por lidar nativamente com variáveis categóricas e exigir menos pré-processamento dos dados. Apesar de sua simplicidade e estabilidade, o *CatBoost* apresentou desempenho inferior em comparação ao *Random Forest* e *XGBoost* no equilíbrio das métricas de interesse.

O *Isolation Forest*, apesar do recall elevado (97,07%), apresentou precisão muito baixa (0,56%), gerando um número excessivo de falsos positivos e limitando sua aplicabilidade direta em produção. Este modelo seria mais adequado para etapas exploratórias ou triagem preliminar de anomalias sem rótulos.

Por fim, o *FT-Transformer* apresentou desempenho próximo ao *CatBoost*, com F1-score de 71%, mas com maior custo computacional e complexidade de treinamento, tornando-o menos indicado para um MVP que prioriza simplicidade e eficiência.

Com base nessa análise, conclui-se que o *Random Forest* representa a escolha mais adequada para compor o Produto Mínimo Viável (MVP). O modelo combina alto desempenho preditivo, bom equilíbrio entre precisão e recall, facilidade de implementação e robustez, oferecendo uma base sólida para evolução futura do sistema de detecção de fraudes.

5 Conclusão

Neste projeto de pesquisa buscou-se avaliar a necessidade de aprimorar os mecanismos de auditoria e controle na gestão dos recursos do Cartão PDAF. A pesquisa buscou responder à seguinte questão: "Como utilizar a inteligência artificial (IA) para identificar e prevenir anomalias e fraudes que comprometem a eficiência e a transparência na aplicação desses recursos?"

Diversos tipos de aprendizado de máquina e de modelos de previsão foram identifi-

cados e testados, obtendo-se uma avaliação comparativa da qualidade dos resultados, a qual permitiu sugestões para a continuidade da pesquisa.

5.1 Objetivos

O objetivo geral da pesquisa foi alcançado com o desenvolvimento de uma prova de conceito (PoC) da aplicação de modelos de predição de aprendizado de máquina para identificar anomalias e fraudes na gestão do Cartão PDAF.

Os objetivos específicos foram alcançados:

1. Levantou-se bibliografia relacionada ao PDAF e à detecção de anomalias com inteligência artificial (IA);
2. Coletou-se dados secundários do PDAF e de bases públicas disponíveis relacionadas;
3. Identificou-se modelos de IA aplicáveis e testou-os em bases de dados disponíveis;
4. Avaliou-se o desempenho comparativo dos modelos e propôs-se alternativas para o futuro desenvolvimento de um produto mínimo viável (MVP) de um sistema para identificar anomalias e fraudes na gestão do cartão PDAF.

5.2 Limitações

No desenvolvimento da pesquisa algumas limitações foram identificadas:

1. Falta de acesso aos microdados do dataset do PDAF;
2. Deficiências nas técnicas de balanceamento de dados;
3. Não foi possível realizar o deploy dos modelos treinados em um ambiente com foco na detecção de anomalias do Cartão PDAF
4. Não foi possível testar e validar o pipeline de detecção de anomalias proposto devido à escassez de dados reais

A ausência de microdados limitou significativamente a capacidade de compreender os padrões e a distribuição detalhada das variáveis do problema. Essa limitação reduziu o potencial de análise exploratória e a possibilidade de ajustar de forma mais precisa os modelos de detecção de anomalias. Além disso, impediu a aplicação de técnicas mais sofisticadas de pré-processamento e engenharia de atributos, que poderiam melhorar a performance dos modelos.

5.3 Oportunidades de Trabalhos Futuros

Identificou-se as seguintes oportunidades de trabalhos futuros:

1. Aplicação de técnicas de geração de dados sintéticos para testar os modelos em datasets mais próximos do real;
2. Validação do pipeline e dos modelos desenvolvidos em dados reais
3. Deploy e monitoramento da solução em ambientes reais

O uso de técnicas de geração de dados sintéticos, como GANs (Redes Generativas Adversariais) e SMOTE (*Synthetic Minority Over-sampling Technique*), pode permitir a criação de amostras mais representativas e equilibradas [2, 6, 20]. Isso viabilizaria a simulação de cenários complexos, ajudando a avaliar a robustez dos modelos e a ajustar hiperparâmetros com maior precisão antes da aplicação em ambientes reais [12]. Enquanto isso, essa técnica também permite a anonimização dos dados, garantindo a privacidade das informações sensíveis.

Referências Bibliográficas

- [1] Henry Adobor e Robert Yawson. «The promise of artificial intelligence in combating public corruption in the emerging economies: A conceptual framework». Em: *Science and Public Policy* 50.3 (dez. de 2022), pp. 355–370. ISSN: 0302-3427.
- [2] Sarah N Almuayqil et al. «Ensemble synthesized minority oversampling-based generative adversarial networks and random forest algorithm for credit card fraud detection». Em: *IEEE Access* 11 (2023), pp. 91599–91612. DOI: [10.1109/ACCESS.2023.3306232](https://doi.org/10.1109/ACCESS.2023.3306232).
- [3] Areej Althabatah et al. «Transformative procurement trends: Integrating industry 4.0 technologies for enhanced procurement processes». Em: *Logistics* 7.3 (2023), p. 63.
- [4] Alexander Bakumenko e Ahmed Elragal. «Detecting Anomalies in Financial Data Using Machine Learning Algorithms». Em: *Systems* 10.5 (2022). ISSN: 2079-8954. DOI: [10.3390/systems10050130](https://doi.org/10.3390/systems10050130). URL: <https://www.mdpi.com/2079-8954/10/5/130>.
- [5] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Referência clássica para definições fundamentais de paradigmas de ML. New York: Springer, 2006.
- [6] Nitesh V Chawla et al. «SMOTE: synthetic minority over-sampling technique». Em: *Journal of artificial intelligence research* 16 (2002), pp. 321–357.
- [7] Yury Gorishniy et al. «Revisiting deep learning models for tabular data». Em: *Advances in neural information processing systems* 34 (2021), pp. 18932–18943.
- [8] Xinjian Guo et al. «On the class imbalance problem». Em: *2008 Fourth international conference on natural computation*. Vol. 4. IEEE. 2008, pp. 192–201.
- [9] Trevor Hastie, Robert Tibshirani e Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd. Springer, 2009.
- [10] Xin Huang et al. «Tabtransformer: Tabular data modeling using contextual embeddings». Em: *arXiv preprint arXiv:2012.06678* (2020).
- [11] Sumaiya Thaseen Ikram et al. «Anomaly detection using XGBoost ensemble of deep neural network models». Em: (2021).
- [12] Eromosele Ileberi, Yan Sun e Zhaohui Wang. «A deep learning ensemble with data resampling for credit card fraud detection». Em: *IEEE Access* 11 (2023), pp. 30554–30566. DOI: [10.1109/ACCESS.2023.3262627](https://doi.org/10.1109/ACCESS.2023.3262627).
- [13] Dmitry Ivanov e Alexander Nesterov. «Identifying bid leakage in procurement auctions: Machine learning approach». Em: *Proceedings of the 2019 ACM Conference on Economics and Computation*. 2019, pp. 69–70.

- [14] Sergei Krutikov et al. «Challenging Gradient Boosted Decision Trees with Tabular Transformers for Fraud Detection at Booking. com». Em: *arXiv preprint arXiv:2405.13692* (2024).
- [15] Rifkie Primartha e Bayu Adhi Tama. «Anomaly detection using random forest: A performance revisited». Em: *2017 International conference on data and software engineering (ICoDSE)*. IEEE. 2017, pp. 1–6.
- [16] Liudmila Prokhorenkova et al. «CatBoost: unbiased boosting with categorical features». Em: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 31. 2018, pp. 6638–6648. URL: <https://papers.nips.cc/paper/2018/hash/14491b756b3a51daac41c24863Abstract.html>.
- [17] Manuel J García Rodríguez et al. «Collusion detection in public procurement auctions with machine learning algorithms». Em: *Automation in Construction* 133 (2022), p. 104047.
- [18] Iqbal H. Sarker. «Machine learning: Algorithms, real-world applications and research directions». Em: *SN Computer Science* 2.3 (2021). Survey moderno excelente para justificar a divisão das categorias de aprendizado., p. 160. DOI: [10 . 1007 / s42979-021-00592-x](https://doi.org/10.1007/s42979-021-00592-x).
- [19] Ting Sun e Leonardo J Sales. «Predicting public procurement irregularity: An application of neural networks». Em: *Journal of Emerging Technologies in Accounting* 15.1 (2018), pp. 141–154.
- [20] Y. Wang. «A Data Balancing and Ensemble Learning Approach for Credit Card Fraud Detection». Em: *2025 4th International Symposium on Computer Applications and Information Technology (ISCAIT)*. IEEE. 2025, pp. 386–390. DOI: [10.1109/ISCAIT64916.2025.11010591](https://doi.org/10.1109/ISCAIT64916.2025.11010591).
- [21] Dong Xu et al. «An improved data anomaly detection method based on isolation forest». Em: *2017 10th international symposium on computational intelligence and design (ISCID)*. Vol. 2. IEEE. 2017, pp. 287–291.
- [22] Hao Zhao e Yu Wang. «A big data-driven financial auditing method using convolution neural network». Em: *Ieee Access* 11 (2023), pp. 41492–41502.